

Universidade Federal do Rio de Janeiro

Instituto de Matemática — Departamento de Ciência da Computação

Construção de Bancos de Dados

Arquiteturas de Armazenamento Físico para SBD: Um estudo sobre DAS, Interfaces e Níveis de RAID

Daniel Rebouças de Sousa Barros — DRE 123273542

Hugo Leandro Antunes — DRE 123143543

Jeson Wen Chen — DRE 123051893

João Batista Brasil Junior — DRE 121091172

Pedro Cintra Silveira — DRE 123419342

Prof. Milton Ramirez

Setembro de 2026

Sumário

Resumo	3
1 Introdução	3
1.1 Metodologia e delimitações	3
2 Interfaces para DAS (Direct Attached Storage)	4
2.1 SATA (Serial ATA)	4
2.2 eSATA (External SATA)	4
2.3 SAS (Serial Attached SCSI)	5
2.4 FireWire (IEEE 1394)	5
2.5 USB 3.x e USB4	5
2.6 HBA (Host Bus Adapter)	6
2.7 Comparação das Interfaces DAS	6
3 Fundamentos de RAID: Paralelismo e Redundância	6
3.1 Paralelismo e Performance	7
3.2 Redundância, Disponibilidade e Confiabilidade	7
3.3 Gargalos e Limitações Práticas do Paralelismo	8
4 Técnicas de Distribuição de Dados (Striping)	8
4.1 Bit-level striping (Distribuição em nível de bit)	8
4.2 Byte-level striping (Distribuição em nível de byte)	8
4.3 Block-level striping (Distribuição em nível de bloco)	9
5 Técnicas de Replicação (Mirroring e Shadowing)	10
5.1 Mirroring (Espelhamento)	11
5.2 Shadowing	11
6 Métricas de Confiabilidade e Falhas	11
6.1 MTTF (Mean Time to Failure)	11
6.2 MTTR (Mean Time to Repair)	12
6.3 MTBF (Mean Time Between Failures)	12
6.4 MTDDL (Mean Time to Data Loss)	12
6.5 Impacto das Métricas na Escolha do RAID para SBDs	13
7 Níveis de RAID Padrão e Bloco de Paridade	14
7.1 Conceito de Bloco de Paridade e Operação XOR	14
7.2 RAID 0 — Striping Puro (Sem Redundância)	14
7.3 RAID 1 — Mirroring (Espelhamento)	15
7.4 RAID 2 — ECC em Nível de Bit (Código de Hamming)	16
7.5 RAID 3 — Paridade Dedicada com Distribuição Fina	16
7.6 RAID 4 — Paridade Dedicada em Nível de Bloco	16
7.7 RAID 5 — Paridade Distribuída em Nível de Bloco	17
7.8 RAID 6 — Dupla Paridade Distribuída (P+Q)	18

7.9	RAID 0+1 e RAID 10 — Combinações de Striping e Mirroring	18
7.10	Tabela Comparativa dos Níveis RAID Padrão	19
7.11	Exemplo comparativo de dimensionamento	20
7.12	Integridade, reconstrução e limites da proteção	20
8	Níveis de RAID Não Padrão	21
8.1	RAID 1.5 (HighPoint)	21
8.2	RAID 7 (Storage Computer Corporation)	21
8.3	RAID-DP (NetApp)	21
8.4	RAID-S (EMC/Symmetrix)	22
8.5	Intel Matrix RAID	22
8.6	Síntese das variantes	22
9	Integração DAS e RAID em SBDs	22
10	Conclusão	24
11	Autoria e uso de IA	24
12	Post-Mortem	24
12.1	Divisão de responsabilidades	24
12.2	Decisões do grupo	25
12.3	O que a revisão corrigiu	25
12.4	Erros gerados pela IA e correções realizadas	25
	Referências bibliográficas	28

Resumo

Este relatório técnico analisa as arquiteturas de armazenamento de dados com conexão direta (DAS) e os arranjos redundantes de discos independentes (RAID) no contexto de Sistemas de Banco de Dados (SBD). O estudo avalia as principais interfaces de hardware (SATA, SAS, USB, eSATA, FireWire, HBA), distinguindo taxas de enlace, desempenho dos dispositivos e recursos do HBA. Em seguida, examina os fundamentos matemáticos e operacionais do paralelismo de *striping* (níveis de bloco e bit) e da resiliência provida por espelhamento, paridade e códigos de dupla falha. O documento detalha as garantias, limitações de gargalo de escrita e aplicações dos níveis de RAID padronizados (0 a 6 e 10) e soluções proprietárias (como RAID-DP e Matrix), correlacionando os atributos de cada camada de armazenamento físico às exigências de desempenho, confiabilidade e vazão de cargas transacionais (OLTP) e analíticas (OLAP).

1 Introdução

O crescimento exponencial da capacidade de processamento e da memória primária em servidores modernos criou uma disparidade significativa em relação à tecnologia de armazenamento secundário mecânico, cujos tempos de acesso limitam o desempenho geral do sistema [?]. Em Sistemas de Banco de Dados (SBD), aplicações web e multimídia, o volume de dados cresce a uma taxa superior à evolução da performance individual dos discos rígidos. Para mitigar esse gargalo, o projeto físico de SBDs emprega conjuntos de múltiplos discos operando em paralelo. O agrupamento físico aumenta a taxa de transferência e o volume de operações de I/O suportado, mas introduz um novo problema: a probabilidade de falha no sistema escala com o número de componentes, ameaçando a integridade dos dados [?].

A solução para o duplo desafio de performance e confiabilidade é a arquitetura RAID (*Redundant Arrays of Independent Disks*), formalizada por Patterson, Gibson e Katz na Universidade de Berkeley em 1988 [?]. O modelo RAID combina paralelismo na distribuição de dados e redundância para tolerância a falhas, e sua taxonomia original — definindo os níveis 1 a 5 — foi posteriormente expandida pela indústria e pela academia para incluir os níveis 0, 6 e combinações aninhadas. As fontes de base são *Database System Concepts*, de Silberschatz, Korth e Sudarshan [?]; *Fundamentals of Database Systems*, de Elmasri e Navathe [?]; e *Database Systems: The Complete Book*, de Garcia-Molina, Ullman e Widom [?]. Em conjunto com a escolha adequada da interface física de armazenamento com conexão direta (DAS, do inglês *Direct Attached Storage*), a configuração correta do nível de RAID determina a capacidade do SBD de atender a altas cargas transacionais (OLTP) ou analíticas (OLAP). Este relatório analisa as principais interfaces de hardware DAS, detalha os fundamentos matemáticos e estruturais dos diferentes níveis de RAID e discute suas aplicações e impactos diretos no projeto de SBDs críticos.

1.1 Metodologia e delimitações

Os livros indicados no enunciado orientam os conceitos; dados de interfaces e produtos são confrontados com documentação primária. Exemplos numéricos são cálculos didáticos, não medições. Os argumentos sobre busca e rotação referem-se a HDDs; em SSDs, latência eletrônica, filas, endurance e proteção contra perda de energia passam a ser determinantes. As comparações de capacidade supõem discos de

mesma capacidade, sem descontar metadados, formatação ou hot spares. As datas de acesso às fontes web constam nas referências; as fontes adicionais desta revisão foram consultadas em 11 de setembro de 2026. Documentos históricos preservados por terceiros são identificados na bibliografia.

2 Interfaces para DAS (Direct Attached Storage)

DAS designa o armazenamento conectado diretamente ao computador, sem uma rede de armazenamento intermediária. A ligação pode ser interna ou externa; um gabinete SAS externo também pode ser DAS. HBA é uma categoria de adaptador, enquanto SATA, SAS e USB especificam interfaces/protocolos. A topologia e o acesso devem ser analisados separadamente do nível RAID [?].

2.1 SATA (Serial ATA)

SATA substituiu a interface paralela ATA por enlaces seriais. As gerações são identificadas pelas taxas de sinalização, conforme a SATA-IO. Os valores da Tabela 1 descontam somente a codificação 8b/10b; comandos, enquadramento e limites do dispositivo reduzem a transferência útil [?, ?].

Interface	Taxa bruta	Após 8b/10b	Fonte / acesso
SATA 1,5 Gb/s	1,5 Gb/s	150 MB/s	[?, ?]; 10/09/2026
SATA 3 Gb/s	3 Gb/s	300 MB/s	[?, ?]; 10/09/2026
SATA 6 Gb/s	6 Gb/s	600 MB/s	[?]; 10/09/2026

Tabela 1: Taxas SATA: limites de enlace, não resultados de benchmark.

AHCI é a interface de programação do controlador para o software, não o protocolo físico SATA. SATA transporta comandos ATA. NVMe é uma interface/protocolo distinto, que no armazenamento local utiliza normalmente PCIe; não é uma modalidade de SATA. Controladoras com suporte a vários protocolos mantêm essa distinção [?]. NCQ permite comandos pendentes e reordenação no dispositivo; a implementação AHCI oferece até 32 posições de comando por porta. O suporte a NCQ e a remoção a quente depende da combinação de controlador, dispositivo, driver e instalação [?]. Em HDDs, reordenar acessos pode reduzir deslocamentos mecânicos. Em SSDs, a ausência desse custo muda o perfil de desempenho; a taxa SATA, por si só, não define os IOPS do dispositivo.

Para SBDs, SATA é uma opção quando capacidade, custo e desempenho medido atendem à carga. Não há fundamento para classificar todo disco SATA como inadequado a dados críticos: proteção contra perda de energia, firmware, redundância e recuperação precisam ser avaliados no produto concreto. CRC de enlace detecta erros de transmissão, mas não comprova integridade de toda a cadeia de armazenamento [?].

2.2 eSATA (External SATA)

A SATA-IO publicou requisitos externos de conectores, cabos e sinais em 2004. O eSATA preserva o transporte SATA, mas possui requisitos elétricos próprios e cabeamento externo de até 2 metros; não é apenas um conector SATA interno com outra forma. A versão convencional não fornece energia pelo cabo, exigindo alimentação separada [?]. Variantes combinadas de alimentação devem ser identificadas pelo equipamento, sem pressupor compatibilidade universal.

É aplicável a expansão e backup externo em instalações que já dispõem da porta. A ausência de uma ponte USB-SATA reduz uma camada de tradução, mas não demonstra menor latência que qualquer dispositivo USB: mídia, controlador e carga podem dominar o resultado. Remoção a quente tampouco dispensa desmontagem e sincronização dos dados pelo sistema.

2.3 SAS (Serial Attached SCSI)

SAS transporta comandos SCSI em enlaces seriais e pode conectar discos e gabinetes por meio de expanders. Dispositivos de duas portas permitem caminhos redundantes, desde que o restante da instalação e o software os suportem. A profundidade de fila depende do produto: por exemplo, o manual do Barracuda ES.2 SAS especifica 128 comandos, em vez de um valor fixo para toda a família SAS [?].

O enlace permite comunicação nos dois sentidos; isso não faz um único HDD executar duas operações mecânicas independentes ao mesmo tempo. Compatibilidade com discos SATA, número de dispositivos, proteção T10-PI e multipathing devem ser confirmados no controlador e na cadeia completa. A comparação entre SAS e SATA precisa considerar esses recursos e o suporte operacional, além da taxa nominal [?, ?].

Como exemplo de conversão, o SAS-4/24G SAS opera a 22,5 Gb/s com codificação 128b/150b [?]. Logo:

$$22,5 \times \frac{128}{150} \times \frac{1000}{8} = 2.400 \text{ MB/s.}$$

Esse resultado vale por direção. A soma dos sentidos é 4.800 MB/s antes de outras sobrecargas. Não corresponde a uma leitura unidirecional a 4.800 MB/s. Em SBDs, SAS é indicado quando caminhos redundantes, manutenção e recursos de gerenciamento justificam o custo; a escolha não dispensa comparar HDDs e SSDs adequados à carga.

2.4 FireWire (IEEE 1394)

FireWire é uma interface serial histórica que permite interligação de dispositivos e tráfego assíncrono e isocrônico, padronizada pela IEEE como IEEE 1394 [?]. O controlador TSB83AA23 da Texas Instruments exemplifica suporte às classes de 100, 200, 400 e 800 Mb/s [?]. Esses valores são taxas de barramento, não vazão garantida de arquivos. O transporte isocrônico atende aplicações temporizadas; operações de armazenamento não passam a ter durabilidade transacional por usá-lo. O alcance depende do meio físico e do modo definidos no padrão; o comprimento de uma ligação não deve ser generalizado para todas as modalidades IEEE 1394 [?].

Para comparação, as classes FireWire 400 e 800 correspondem nominalmente a 50 e 100 MB/s antes de sobrecargas, por simples divisão por oito. Alimentação depende do conector e da implementação; não se deve prometer potência pelo nome da interface. Em um projeto novo de SBD, sua inclusão só se justifica por compatibilidade com equipamentos existentes e suporte disponível. Seu estudo ilustra a evolução do DAS externo, sem exigir tratá-lo como alternativa atual equivalente a SAS ou USB4.

2.5 USB 3.x e USB4

USB 3.2 reúne as modalidades Gen 1 (5 Gb/s), Gen 2 (10 Gb/s) e Gen 2x2 (20 Gb/s). O modo de duas pistas exige conexão compatível, e o formato USB-C sozinho não informa a velocidade disponível [?].

USB4 introduziu modos de 20 e 40 Gb/s e também multiplexa protocolos [?], podendo compartilhar recursos entre dados e vídeo. A especificação v2.0 introduz 80 Gb/s e operação opcional assimétrica de 120 Gb/s em um sentido e 40 Gb/s no outro, com sinalização PAM3 [?].

USB Power Delivery define separadamente a negociação de energia; a geração de dados não garante potência de alimentação. Fonte, cabo e dispositivo precisam ser compatíveis [?]. Para armazenamento, deve-se distinguir BOT de UAS/UASP: o último permite filas de comandos, mas requer suporte da ponte e do driver. No USB4, uma unidade também pode usar tunelamento PCIe; não se deve descrever todo armazenamento USB4 como tradução USB-SATA [?, ?].

Backup portátil, desenvolvimento e expansão externa são aplicações possíveis. O uso em produção exige testar persistência de escritas, desconexão, recuperação e desempenho sob concorrência; uma taxa nominal elevada não resolve esses requisitos.

2.6 HBA (Host Bus Adapter)

Um HBA conecta o host a dispositivos de armazenamento. Há HBAs para DAS e para redes de armazenamento; a sigla não implica exclusivamente SAS nem define um nível RAID [?]. Um adaptador SAS em passthrough expõe discos ao sistema operacional, que pode implementar RAID por software. Uma controladora RAID apresenta volumes lógicos e executa parte da gestão de redundância no adaptador. Produtos podem combinar modos, mas cache protegido e aceleração de paridade não são requisitos de todo HBA [?].

A seleção deve verificar largura e geração do enlace PCIe, portas, firmware, drivers, capacidade de filas e política de cache. Para o SBD, confirmar uma escrita em cache protegido pode reduzir a latência; a proteção precisa sobreviver às falhas consideradas e respeitar comandos de sincronização. RAID por software também pode usar CPUs modernas e dispositivos com proteção contra perda de energia; não existe vencedor universal apenas pela localização da lógica.

2.7 Comparação das Interfaces DAS

SuperSpeed USB utiliza caminhos separados de transmissão e recepção, permitindo tráfego simultâneo nos dois sentidos (dual-simplex/full-duplex). O fato de uma transação ter direção definida não torna o enlace half-duplex. UASP trata do transporte de comandos, não da criação dessa capacidade física [?, ?]. Para USB4 a 80 Gb/s, não há exigência universal de certificação Thunderbolt 4: a USB-IF prevê cabos passivos de 40 Gb/s existentes e novos cabos ativos de 80 Gb/s, com host e dispositivo compatíveis [?].

3 Fundamentos de RAID: Paralelismo e Redundância

A tecnologia RAID (*Redundant Array of Independent Disks*) foi desenvolvida para mitigar o gargalo de desempenho de entrada e saída (I/O) em sistemas computacionais e, simultaneamente, contornar a redução na confiabilidade inerente ao uso de múltiplos discos físicos [?]. Para atingir esses objetivos em Sistemas de Banco de Dados (SBD), as arquiteturas RAID fundamentam-se em dois princípios: o paralelismo e a redundância [?].

Interface	Taxa de enlace	Conexão e manutenção	Protocolo / aplicação
SATA interno	Até 6 Gb/s; 600 MB/s após 8b/10b	Cabo interno até 1 m; hot-plug condicionado à instalação	Comandos ATA; AHCI é a interface de programação. Capacidade econômica.
eSATA	Taxa da geração SATA suportada	Até 2 m; alimentação separada; hot-plug condicionado	Transporte SATA externo; expansão e backup.
SAS-4	22,5 Gb/s por direção; 2.400 MB/s após codificação	Comprimento, filas e expansão dependem do produto; caminhos redundantes quando suportados	SCSI; full-duplex; gerenciamento e manutenção de storage.
FireWire	Classes 400/800 Mb/s; limites nominais de 50/100 MB/s	Cabo, alimentação e alcance dependem do modo e conector	IEEE 1394; tráfego assíncrono/isocrônico; instalações legadas.
USB 3.2	5/10/20 Gb/s	Cabo e dispositivos compatíveis com o modo; hubs compartilham banda	SuperSpeed full-duplex; BOT ou UASP para armazenamento.
USB4 v2.0	Até 80 Gb/s por sentido; opcional 120/40 Gb/s	Cabos passivos de 40 Gb/s compatíveis ou novos ativos de 80 Gb/s	Túneis USB/PCIe/DP; banda compartilhada; expansão externa.
HBA	Depende de PCIe e dos enlaces de storage	Hot-plug de discos e da placa são recursos distintos e condicionais	Adaptador; passthrough ou funções RAID conforme o produto.

Tabela 2: Comparação DAS. Taxas não são benchmarks. Fontes: SATA/AHCI [?, ?, ?]; SAS [?, ?]; FireWire [?, ?]; USB [?, ?, ?]; HBA [?].

3.1 Paralelismo e Performance

O desempenho de um sistema de armazenamento é limitado pelas características mecânicas e eletrônicas de uma única unidade de disco [?]. Ao agrupar diversos discos sob uma única interface lógica, o RAID amplia o paralelismo em duas frentes:

- **Taxa de transferência:** requisições extensas são divididas em fragmentos menores que múltiplos discos leem ou gravam simultaneamente, reduzindo o tempo total da operação em comparação com um disco sequencial [?].
- **Vazão de I/O (*throughput*):** em ambientes transacionais (OLTP), discos diferentes atendem a requisições pequenas e independentes, elevando o número de operações de I/O por segundo (IOPS) processado [?].

3.2 Redundância, Disponibilidade e Confiabilidade

A adição de múltiplos discos independentes introduz um desafio estatístico: a probabilidade de falha de pelo menos um disco em um *array* grande é significativamente maior do que a de um disco isolado [?]. Se cada disco tem probabilidade q de falhar no intervalo considerado e as falhas são independentes, a probabilidade de pelo menos uma falha é $1 - (1 - q)^n$. Essa dedução explicita a diferença entre falha de componente e perda de dados no array redundante. Para que o agrupamento seja viável em ambientes críticos, o RAID armazena informações adicionais — cópias exatas dos dados ou cálculos de paridade — que permitem a reconstrução do estado original no caso de falhas físicas [?].

Essa redundância contribui para dois atributos, dentro do modelo de falhas suportado. O primeiro é a **confiabilidade**: a capacidade do sistema de preservar a integridade da informação ao longo do tempo, reduzindo a probabilidade de perda permanente de dados [?]. O segundo é a **disponibilidade**: a resiliência operacional que permite ao banco de dados continuar atendendo a consultas e atualizações durante certas falhas de disco, com possível degradação de desempenho, enquanto aguarda a substi-

tução do hardware danificado, pois o controlador RAID calcula os dados faltantes a partir dos discos sobreviventes [?].

3.3 Gargalos e Limitações Práticas do Paralelismo

O ganho efetivo de desempenho com múltiplos discos é limitado por quatro fatores que o projetista do SBD deve dimensionar. O primeiro é o *overhead* do controlador: o processamento da distribuição e reagregação dos dados consome ciclos de CPU ou do processador do HBA. O segundo é a contenção no barramento: se múltiplos discos compartilham o mesmo canal físico (e.g., um único canal SAS), a largura de banda do canal torna-se o gargalo independentemente do número de discos. O terceiro é o desbalanceamento de carga: se os dados não estão uniformemente distribuídos, alguns discos tornam-se pontos quentes (*hotspots*) enquanto outros permanecem ociosos. O quarto é o *straggler effect*: em operações que exigem dados de múltiplos discos, o tempo de resposta é determinado pelo disco mais lento, limitando o ganho agregado [?]. O *striping* uniforme e o dimensionamento correto do *strip size* são as principais ferramentas para mitigar esses fatores.

4 Técnicas de Distribuição de Dados (Striping)

A técnica de *data striping* (distribuição de dados) fraciona os dados em unidades de tamanho fixo — denominadas *strips* ou *chunks* — e os espalha por múltiplos discos independentes com o objetivo de maximizar o paralelismo das operações de I/O [?]. O tamanho da unidade de distribuição (*strip size* ou *chunk size*) é um parâmetro de configuração crítico que determina a granularidade do paralelismo [?]: uma granularidade fina (bit ou byte) maximiza o paralelismo para requisições individuais grandes, mas introduz *overhead* de sincronização e torna cada requisição dependente de todos os discos; uma granularidade grossa (bloco ou múltiplos blocos) permite que requisições pequenas sejam atendidas por um único disco, melhorando o *throughput* para cargas de trabalho com alta concorrência de requisições independentes. A técnica admite três granularidades principais — bit, byte e bloco — apresentadas abaixo; a escolha entre elas define o perfil de desempenho do *array* e, consequentemente, o nível de RAID mais adequado.

4.1 Bit-level striping (Distribuição em nível de bit)

O *bit-level striping* divide os bits de cada byte de forma que cada bit seja armazenado em um disco distinto [?]. Em um *array* de oito discos, por exemplo, o bit i de cada byte é gravado no disco i . Nesse modelo, cada operação de I/O acessa todos os discos simultaneamente, permitindo ganho de transferência próximo ao número de discos de dados quando os demais componentes não limitam o acesso [?]. A contrapartida é que cada requisição ocupa todos os braços de leitura e gravação, impedindo que requisições menores e independentes sejam processadas em paralelo — limitação severa em cargas OLTP. Na prática, o *bit-level striping* é raramente utilizado em sistemas contemporâneos, sendo encontrado historicamente em implementações de RAID 2 com códigos de Hamming [?].

4.2 Byte-level striping (Distribuição em nível de byte)

O *byte-level striping* distribui bytes inteiros ciclicamente entre os discos, de modo que bytes consecutivos de um mesmo arquivo residem em discos diferentes [?, ?]. Em um *array* de n discos, o byte j é alocado

no disco ($j \bmod n$). Assim como o *bit-level striping*, esta granularidade faz com que cada requisição de I/O utilize todos os discos simultaneamente, oferecendo alta taxa de transferência para operações sequenciais de grande volume. O gargalo é o mesmo: a concorrência de requisições independentes é inexistente — o sistema comporta apenas uma requisição de cada vez, pois todos os braços são mobilizados por ela. O *byte-level striping* é a base operacional do RAID 3, onde é frequentemente chamado de *bit-interleaved* na terminologia de Silberschatz ou *byte-level* em outras fontes [?]. O RAID 2 clássico emprega distribuição em nível de bit com código de Hamming, conforme a subseção específica; byte-level e bit-level não são a mesma granularidade. Não tem uso prático independente em instalações modernas, mas sua compreensão é essencial para entender por que RAID 5 (nível de bloco) suplantou RAID 2 e RAID 3.

4.3 Block-level striping (Distribuição em nível de bloco)

O *block-level striping* distribui blocos lógicos inteiros entre os discos, e o *array* é tratado pelo sistema operacional como um único disco de grande capacidade [?]. Em um RAID 0 didático, com cada unidade de distribuição igual a um bloco e índices lógicos iniciados em zero, os blocos são gravados em padrão circular (*round-robin*): em um conjunto de n discos, o bloco lógico i é alocado no disco $(i \bmod n) + 1$ [?]. Silberschatz, Korth e Sudarshan [?] demonstram que o *block-level striping* oferece o melhor equilíbrio entre paralelismo e concorrência: para requisições grandes (varreduras sequenciais de tabelas), múltiplos blocos consecutivos são lidos em paralelo de discos diferentes, alcançando *throughput* proporcional ao número de discos; para requisições pequenas (leituras aleatórias de índices B-tree), cada requisição é atendida por um único disco, permitindo que o *array* processe n requisições independentes simultaneamente. Nos níveis com paridade, o mapeamento também reserva posições para redundância; a expressão anterior não é sua fórmula geral de endereçamento. É essa dupla vantagem que torna o *block-level striping* a base dos níveis RAID 0, 4, 5 e 6.




Figura 1: Comparação entre *bit-level striping* (a) e *block-level striping* (b) em um *array* de 4 discos. Em (a), bits sucessivos são distribuídos ciclicamente pelos discos; em (b), blocos inteiros são distribuídos em padrão *round-robin*. Adaptado de [?].

5 Técnicas de Replicação (Mirroring e Shadowing)

Para garantir redundância e proteger os dados contra falhas físicas, as arquiteturas de armazenamento utilizam técnicas de replicação. Neste documento, adotamos a seguinte convenção terminológica, alinhada às fontes consultadas: ***mirroring*** (espelhamento) refere-se à técnica, implementada por hardware ou software, de manter cópias físicas idênticas em discos distintos — base do RAID 1; ***shadowing***, no contexto de hardware de discos, é tratado como sinônimo de *mirroring* por Silberschatz, Korth e Sudarshan [?] (seção 12.5) e por Elmasri e Navathe [?] (seção 16.10). Já ***shadow paging*** designa uma técnica distinta de recuperação transacional, apresentada na subseção seguinte.

5.1 Mirroring (Espelhamento)

O *mirroring* é a técnica de redundância primária em sistemas de discos e a base do nível RAID 1 [?]. Cada operação de gravação (*write*) solicitada pelo SBD é executada integralmente em todos os discos que compõem o espelho, enquanto as operações de leitura (*read*) podem ser distribuídas entre os discos para melhorar o desempenho. Elmasri e Navathe [?] detalham que, em *arrays* espelhados com m cópias, o controlador pode direcionar requisições de leitura ao disco cujo atuador está mais próximo do setor solicitado, reduzindo a latência média; o *throughput* de leitura é teoricamente multiplicado por m . O *throughput* de escrita, contudo, é limitado pelo disco mais lento do par, pois toda escrita deve ser replicada em todas as cópias. Com *write-back caching* protegido e semântica de persistência correta, as escritas podem ser confirmadas à aplicação antes da replicação completa, mitigando a penalidade de latência. No caso de duas cópias, são necessários $2n$ discos para armazenar a capacidade de n , um overhead de 100% que faz do RAID 1 uma escolha para volumes de alta criticidade como *write-ahead logs* (WAL) e metadados do SBD. Silberschatz, Korth e Sudarshan [?] recomendam espelhamento para *logs* de transação (*redo/undo logs*), onde a perda de dados pode comprometer a propriedade de durabilidade (D) do modelo ACID.

5.2 Shadowing

No contexto de discos do enunciado, *shadowing* e *mirroring* designam o espelhamento: manter cópias físicas do mesmo conteúdo. Esse uso aparece explicitamente no material dos autores de *Database System Concepts* [?].

Shadow paging é outro conceito, pertencente à recuperação transacional. Em uma implementação básica, atualizações são escritas em novas páginas, preservando a tabela anterior. Após persistir as páginas e a nova tabela, o commit muda atômica e persistentemente a referência para a nova versão. Uma falha antes dessa mudança preserva o estado antigo; depois dela, a recuperação deve reconhecer o estado confirmado. Isso não exige cópias em discos independentes e, portanto, não fornece por si só tolerância à perda física da unidade [?].

6 Métricas de Confiabilidade e Falhas

A avaliação quantitativa da confiabilidade de um sistema de armazenamento baseado em RAID depende de um conjunto de métricas estatísticas derivadas da teoria de confiabilidade [?]. Elas permitem ao projetista do SBD comparar objetivamente configurações de RAID e estimar a vida útil do sistema antes que ocorra perda irreversível de dados.

6.1 MTTF (Mean Time to Failure)

O MTTF (*Mean Time to Failure*) é o tempo médio esperado até que um componente individual — tipicamente um disco rígido — apresente falha permanente [?]. Valores publicados por fabricantes são estimativas populacionais sob condições especificadas, não garantias individuais nem prazo de substituição.

Para um disco isolado com MTTF de M horas, a taxa de falha instantânea (assumindo distribuição exponencial) é $\lambda = 1/M$. Quando n discos independentes operam simultaneamente, a taxa combinada

passa a $\lambda_{\text{grupo}} = n/M$, e o MTTF do grupo — o tempo até que *qualquer* disco falhe — é:

$$\text{MTTF}_{\text{grupo}} = \frac{M}{n} \quad (1)$$

Um *array* de 100 discos com MTTF individual de 1.200.000 horas tem MTTF de grupo de apenas 12.000 horas ($\approx 1,4$ anos), o que ilustra a necessidade da redundância [?].

6.2 MTTR (Mean Time to Repair)

O MTTR (*Mean Time to Repair*) quantifica o tempo médio necessário para detectar uma falha, substituir o componente defeituoso e reconstruir integralmente os dados a partir da redundância disponível [?]. Em contexto de RAID, esse tempo inclui a detecção pelo controlador ou monitoramento, a intervenção humana ou logística para substituição física e o *rebuild*, durante o qual o controlador lê os discos sobreviventes e recomputa os blocos faltantes no disco substituído.

O MTTR define a **janela de vulnerabilidade**: o período em que o sistema opera em modo degradado, sem redundância completa. Se um segundo disco falhar durante essa janela, pode ocorrer perda permanente de dados [?]. O tempo de reconstrução depende dos bytes a recompor, da banda efetiva disponível e da concorrência com a aplicação. Uma estimativa inicial é $T_{\text{rebuild}} \approx B/v$, somando-se detecção e logística; não há faixa de horas universal para uma dada capacidade.

6.3 MTBF (Mean Time Between Failures)

MTBF é uma medida associada a falhas de sistemas reparáveis. É necessário explicitar a base temporal: neste estudo, adota-se a convenção de tempo operacional entre falhas, coerente com a estimativa por tempo total de operação dividido pelo número de falhas apresentada pelo NIST [?]. Se U é o tempo médio operacional e D o tempo médio indisponível por ciclo, então

$$\text{MTBF}_{\text{operacional}} = U, \quad T_{\text{ciclo}} = U + D. \quad (2)$$

Sob taxa constante de falha λ , $U = 1/\lambda$. Uma convenção que conte o intervalo de calendário entre falhas incluirá também D ; não se deve misturar essa contagem com o MTBF operacional. MTTF e MTBF tampouco são garantias de vida útil de uma unidade.

Para um serviço que alterna entre operação e indisponibilidade, a disponibilidade estacionária é

$$A = \frac{U}{U + D}.$$

O tempo de reconstrução de um RAID degradado não deve ser automaticamente usado como D : o serviço pode permanecer disponível durante o rebuild. Falha de componente, indisponibilidade e perda de dados são eventos distintos [?].

6.4 MTDDL (Mean Time to Data Loss)

O MTDDL (*Mean Time to Data Loss*) é o tempo médio até perda permanente de dados. No modelo restrito de falhas de discos abaixo, a perda ocorre quando a redundância disponível deixa de permitir a reconstrução; fora desse modelo, também pode resultar de erros latentes, corrupção ou falhas comuns. Mantidos o número de discos e o MTTF individual, as aproximações seguintes dão $\text{MTDDL}_5 \propto 1/R$ e

$\text{MTTDL}_6 \propto 1/R^2$, com $R = \text{MTTR}$. Reduzir R à metade duplica o MTTDL de RAID 5 e quadruplica o de RAID 6. Os expoentes dois e três no numerador referem-se ao MTTF individual, não ao ganho obtido com a redução do reparo. Para explicitar as hipóteses, seja $M = 1/\lambda$ o MTTF de cada disco e $R = 1/\mu$ o tempo médio de reparo. Adota-se aqui um modelo didático de Markov: discos idênticos, falhas independentes e exponenciais, reparos exponenciais com taxa μ e **um reparo por vez**. Excluem-se erros latentes, falhas correlacionadas, falhas de controlador e erro humano. Os resultados seguintes são derivações sob essas premissas, não especificações de produto.

Para um par espelhado ou um RAID 5 com n discos, a primeira falha ocorre à taxa $n\lambda$. No estado degradado, a probabilidade de outra falha anteceder o reparo é

$$\frac{(n-1)\lambda}{\mu + (n-1)\lambda} \approx (n-1)\lambda R, \quad n\lambda R \ll 1.$$

Multiplicando essa probabilidade pela taxa de entrada no estado degradado e invertendo o resultado, obtêm-se as aproximações dominantes:

$$\text{MTTDL}_{1, 2 \text{ cópias}} \approx \frac{M^2}{2R}, \quad (3)$$

$$\text{MTTDL}_5 \approx \frac{M^2}{n(n-1)R}. \quad (4)$$

Para RAID 6, o caminho raro até a perda passa de zero para um, dois e três discos falhados antes dos reparos. No modelo de reparo serial adotado, seu termo dominante é

$$\text{MTTDL}_6 \approx \frac{M^3}{n(n-1)(n-2)R^2}. \quad (5)$$

Com reparos independentes em paralelo, a taxa de saída do estado com duas falhas pode ser 2μ , alterando o coeficiente; com duração de rebuild fixa, este modelo exponencial também deixa de ser exato. Portanto, a fórmula não deve ser transplantada para uma controladora sem modelar sua política de reconstrução.

Exemplo próprio: para $M = 1.200.000$ h e $R = 24$ h, o par espelhado apresenta aproximadamente 3×10^{10} h; um RAID 5 de oito discos, $1,07 \times 10^9$ h. Esses valores enormes não são previsões de vida útil: revelam quão otimista é excluir causas comuns e erros de leitura. Dentro do modelo, dobrar R reduz pela metade o MTTDL de RAID 5 e a um quarto o de RAID 6. A análise serve para estudar sensibilidade; uma estimativa operacional precisa considerar mecanismos adicionais de falha [?, ?].

6.5 Impacto das Métricas na Escolha do RAID para SBDs

As métricas acima guiam diretamente decisões de projeto em bancos de dados de missão crítica [?]:

- **Reduzir o MTTR:** manter discos *hot spare* (sobressalentes conectados e prontos) no *array* permite que a reconstrução inicie sem intervenção humana e diminui a janela de vulnerabilidade.
- **Escolher o nível de RAID:** em *arrays* com muitos discos ou discos de grande capacidade, o tempo de reconstrução torna-se maior; nesse cenário, as equações de MTTDL podem justificar RAID 6 ou RAID 10 em vez de RAID 5.

- **Monitorar preventivamente:** S.M.A.R.T. e análises preditivas ajudam a identificar falhas iminentes e a substituir discos antes da operação degradada.

7 Níveis de RAID Padrão e Bloco de Paridade

Os diferentes níveis de RAID são estratégias distintas de combinação entre as técnicas de *striping* (distribuição de dados) e redundância (espelhamento ou paridade), cada qual otimizando um equilíbrio específico entre desempenho, tolerância a falhas e eficiência de uso do espaço de armazenamento [?]. Os níveis 1 a 5 foram apresentados no artigo seminal de Patterson, Gibson e Katz [?], e os níveis compostos (RAID 0+1 e RAID 10) surgiram posteriormente para combinar vantagens de níveis distintos.

7.1 Conceito de Bloco de Paridade e Operação XOR

Antes de apresentar os níveis individualmente, é fundamental compreender o conceito de **bloco de paridade**, usado nas organizações com paridade em bloco; RAID 2 emprega bits de verificação ECC, enquanto RAID 6 requer duas relações independentes de redundância [?]. A paridade é um valor calculado a partir dos blocos de dados que permite a reconstrução de qualquer bloco individual perdido.

O cálculo baseia-se na operação lógica XOR (*exclusive OR*), que possui a propriedade matemática essencial: se $P = B_1 \oplus B_2 \oplus \dots \oplus B_{n-1}$, então qualquer bloco B_i pode ser reconstruído a partir dos demais blocos e de P :

$$B_i = B_1 \oplus \dots \oplus B_{i-1} \oplus B_{i+1} \oplus \dots \oplus B_{n-1} \oplus P \quad (6)$$

Essa propriedade explica a recuperação de uma perda conhecida com paridade XOR simples: um único bloco de paridade protege $(n - 1)$ blocos de dados contra a perda de qualquer um deles [?].

Exemplo próprio de reconstrução. Considere símbolos de quatro bits: $D_0 = 1010$, $D_1 = 1100$ e $D_2 = 0110$. A paridade é $P = D_0 \oplus D_1 \oplus D_2 = 0000$. Perdido D_1 , recupera-se $D_1 = P \oplus D_0 \oplus D_2 = 1100$. O exemplo supõe que a posição perdida é conhecida e que os demais símbolos estão íntegros. Uma relação XOR simples não resolve duas perdas desconhecidas nem identifica, sozinha, qual bloco foi silenciosamente corrompido.

7.2 RAID 0 — Striping Puro (Sem Redundância)

O RAID 0 implementa exclusivamente *block-level striping*, distribuindo blocos de dados ciclicamente entre n discos sem qualquer forma de redundância [?]. Sem cálculo de paridade nem escrita duplicada, o RAID 0 tem baixo custo adicional; taxa de transferência e IOPS podem crescer com o número de discos, dentro dos limites do controlador, enlace, alinhamento e distribuição da carga. A contrapartida é a ausência de redundância: uma falha pode inutilizar o volume lógico e causar perda de dados, embora não apague fisicamente os blocos dos discos sobreviventes. O MTDDL é de fato menor que o de um disco isolado: $MTTDL_{\text{RAID } 0} = MTTF/n$, sob as hipóteses de discos idênticos e falhas independentes exponenciais. Por essa razão, o RAID 0 é adequado apenas para dados temporários ou descartáveis (tabelas temporárias de *sort*, espaço de *swap* de consultas), nunca para dados persistentes ou *logs* de transação [?].

7.3 RAID 1 — Mirroring (Espelhamento)

O RAID 1 replica cada bloco de dados em dois (ou mais) discos físicos [?]. O desempenho de leitura é superior ao de um disco isolado, pois o controlador distribui requisições entre os discos do par, podendo aproximar-se do dobro dos IOPS de leitura em um par, com carga paralela e balanceada. O desempenho de escrita, por outro lado, é limitado pela velocidade do disco mais lento, no modo write-through; com write-back protegido, a confirmação pode ocorrer no cache persistente antes da gravação em ambos os discos. O nível tolera a falha de até $(m - 1)$ discos em um grupo de m cópias (tipicamente $m = 2$), com eficiência de espaço de $1/m$ (50% para duas cópias). Essa combinação de redundância e reconstrução localizada faz do RAID 1 a escolha preferida para *write-ahead logs* (WAL) e metadados críticos do banco [?] — volumes de menor capacidade nos quais o custo de espaço é justificável.



Figura 2: Visão geral das arquiteturas dos principais níveis RAID: (a) RAID 0 — *striping* sem redundância; (b) RAID 1 — espelhamento completo ($C =$ cópia); (c) RAID 5 — paridade distribuída entre todos os discos (P); (d) RAID 6 — dupla paridade distribuída (P e Q). Adaptado de [?].

7.3.1 Cenário Prático: RAID 1 em Logs de Transação (WAL)

Em PostgreSQL com durabilidade síncrona local, a confirmação de commit depende da persistência dos registros WAL necessários, não da gravação imediata de todas as páginas de dados. Vários commits podem compartilhar um flush; configurar `synchronous_commit=off` permite confirmação antecipada com risco de perder transações recentes após falha. Isso é diferente de desligar `fsync` [?].

Considere, como exemplo próprio, dois discos de 500 GB em espelho: a capacidade útil nominal é 500 GB, antes de metadados. Em write-through, a controladora espera a persistência nas cópias ativas. Em write-back protegido, pode confirmar quando os dados estão em cache recuperável após a falha de energia considerada; posteriormente faz o destage para os discos. Cache volátil sem proteção não deve ser confundido com persistência. Se um membro falhar, o volume pode continuar pelo sobrevivente, sujeito aos timeouts, à política da controladora e à ausência de outras falhas. O RAID não confirma a transação: ele conclui I/O, e o SGBD decide quando confirmar à aplicação.

O espelho é uma opção para WAL pela ausência de atualização de paridade; o benefício de um volume dedicado deve ser medido quando controlador e mídia são compartilhados com os dados. O tamanho de uma página WAL tampouco fixa o tamanho de cada escrita física.

7.4 RAID 2 — ECC em Nível de Bit (Código de Hamming)

O RAID 2 combina *bit-level striping* com discos dedicados a bits de paridade calculados pelo código de Hamming [?]. Cada byte de dados é distribuído bit a bit entre os discos de dados, e os discos adicionais armazenam bits de paridade ECC (*Error-Correcting Code*) que permitem a detecção e a correção de erros de um único bit sem reler o disco defeituoso. O nível é considerado obsoleto: os discos atuais já incorporam ECC internamente na camada de firmware, tornando a proteção do RAID 2 redundante [?]. Além disso, o *bit-level striping* impede o processamento paralelo de requisições independentes, uma limitação que o RAID 5 resolve ao operar em nível de bloco.

Para um código de Hamming simples com k bits de dados e r bits de verificação por palavra, exige-se $2^r \geq k + r + 1$: os padrões de síndrome devem distinguir a ausência de erro e cada posição de erro simples. Por exemplo, quatro bits de dados e três de verificação atendem à desigualdade; esse exemplo não determina um mínimo universal de discos para todo RAID 2. A vantagem histórica é localizar e corrigir erro simples no conjunto; a desvantagem é o custo de unidades de verificação e da operação coordenada.

7.5 RAID 3 — Paridade Dedicada com Distribuição Fina

O RAID 3 emprega distribuição fina, descrita como *bit-interleaved* no material de Silberschatz e frequentemente como *byte-level striping* em outras taxonomias [?]. Em ambos os casos, trata-se de acesso coordenado aos discos com um disco de paridade dedicado [?]: os bytes de dados são distribuídos entre $(n - 1)$ discos, e o n -ésimo disco armazena os bytes de paridade (XOR). A taxa de transferência para operações sequenciais de grande volume — varreduras completas de tabelas, cargas de dados em lote — é excelente, pois todos os discos são acessados simultaneamente para cada requisição. Essa mesma característica, porém, impede que mais de uma requisição de I/O seja processada por vez, tornando o RAID 3 inadequado para cargas OLTP com múltiplas transações concorrentes. Para novas cargas OLTP, níveis em blocos oferecem concorrência mais adequada que essa organização histórica [?].

7.6 RAID 4 — Paridade Dedicada em Nível de Bloco

O RAID 4 utiliza *block-level striping* com um disco de paridade dedicado [?]. A mudança de granularidade em relação ao RAID 3 — blocos inteiros em vez de bytes — permite que requisições de leitura independentes acessem discos diferentes em paralelo, pois cada requisição pequena é atendida por um único disco de dados sem acionar todos os demais.

O gargalo, contudo, migra para o disco de paridade. Para uma escrita de bloco único (*small write*) pelo método RMW, sem aproveitar dados em cache, o controlador executa uma sequência *read-modify-write* (RMW) de **4 operações físicas de I/O**:

1. **Leitura do bloco de dados antigo** no disco de dados;
2. **Leitura do bloco de paridade antigo** no disco de paridade dedicado;
3. **Cálculo da nova paridade:** $P_{\text{novo}} = P_{\text{antigo}} \oplus D_{\text{antigo}} \oplus D_{\text{novo}}$;
4. **Escrita do bloco de dados novo e escrita da nova paridade** — dois I/Os de gravação.

O disco de paridade participa de todas as escritas, tornando-se o ponto único de contenção que limita severamente o IOPS de escrita do array inteiro [?]. Para escritas de stripe completa, a nova paridade é calculada diretamente dos dados novos, eliminando as duas leituras, mas o disco de paridade ainda participa de toda escrita. Esse gargalo é precisamente o que o RAID 5 elimina ao distribuir a paridade ciclicamente entre todos os discos.

7.7 RAID 5 — Paridade Distribuída em Nível de Bloco

O RAID 5 oferece um compromisso entre redundância de uma falha e aproveitamento da capacidade, cuja adequação depende da carga e do risco aceitável [?]. Utiliza *block-level striping* com paridade distribuída ciclicamente entre todos os discos: em um layout ilustrativo, na *stripe k*, o bloco de paridade é armazenado no disco $(k \bmod n)$, e os demais discos contêm blocos de dados [?]. Essa distribuição elimina o ponto único de contenção do RAID 4, pois as escritas de paridade são balanceadas entre todos os discos.

Leituras normais acessam os dados sem reconstrução por paridade; leituras sequenciais e aleatórias exploram a distribuição de forma diferente. Pequenas escritas com read-modify-write leem dado e paridade antigos e gravam ambos atualizados. O custo depende do tamanho e alinhamento da escrita e da presença de dados em cache. O nível garante tolerância à falha de um disco, com espaço útil de $(n-1)/n$ da capacidade bruta total. É amplamente utilizado para armazenamento de dados de leitura intensiva, *data warehouses* e ambientes OLAP [?]. O risco aparece em *arrays* grandes ou com discos de alta capacidade: conforme demonstrado pela Equação 4, o MTDDL degrada-se quadraticamente com n , e reconstruções longas estendem a janela de vulnerabilidade a uma segunda falha.

A Tabela 3 ilustra a distribuição dos primeiros 20 blocos lógicos e dos blocos de paridade em um arranjo de 5 discos, como exemplo próprio do conceito de paridade distribuída [?]. O bloco de paridade da *stripe k* é armazenado no disco $(k \bmod 5)$; para cada conjunto de 4 blocos lógicos ($4k$ a $4k+3$), os demais 4 discos armazenam os dados. O padrão de posições se repete; outros layouts válidos usam outra rotação e ordem dos dados.

Disco 0	Disco 1	Disco 2	Disco 3	Disco 4
P0	0	1	2	3
4	P1	5	6	7
8	9	P2	10	11
12	13	14	P3	15
16	17	18	19	P4

Tabela 3: Distribuição de blocos de dados e paridade em um RAID 5 com 5 discos. Exemplo calculado a partir do layout descrito no texto.

7.7.1 Cenário Prático: RAID 5 com Penalidade de Escrita (Write Penalty)

Cenário: Um catálogo de produtos com muitas consultas e poucas atualizações. Hardware: 4 discos de 1 TB em um arranjo RAID 5 (distribuição bloco a bloco com paridade distribuída). Capacidade útil: $(N - 1) \times 1 \text{ TB} = 3 \text{ TB}$. Para atualizar um único bloco por read-modify-write, sem aproveitar cache, o controlador deve: ler o bloco antigo, ler a paridade antiga, calcular a nova paridade via XOR, e então gravar o bloco novo e a paridade nova — resultando em 4 operações físicas de I/O nessa atualização [?].

Em uma escrita de stripe completa, a paridade é calculada a partir dos novos dados; não é necessário ler dado e paridade antigos. Cache pode agregar atualizações e alterar o custo observado. A penalidade de quatro I/Os não se aplica indistintamente a todo comando de escrita [?].

7.8 RAID 6 — Dupla Paridade Distribuída (P+Q)

O RAID 6 estende o RAID 5 ao empregar dois esquemas de paridade independentes (P e Q), ambos distribuídos entre todos os discos [?]. P é calculado pelo XOR convencional; Em uma implementação Reed–Solomon, Q combina símbolos com coeficientes em campo finito; outros códigos de dupla falha, como RDP, usam relações XOR distintas. Q não pode ser apenas uma cópia de P, pois isso não permitiria resolver duas incógnitas [?, ?]. Essa dupla paridade permite tolerar a falha simultânea de até dois discos. A penalidade de escrita é maior — cada escrita exige a atualização de dois blocos de paridade —, e leituras em modo degradado podem exigir reconstrução; em modo normal, os dados são lidos diretamente. Com espaço útil de $(n - 2)/n$ e exigência mínima de 4 discos, RAID 6 deve ser escolhido pela análise conjunta de capacidade, tempo de *rebuild*, criticidade e risco operacional, e não por um limiar universal de número de discos [?].

7.9 RAID 0+1 e RAID 10 — Combinações de Striping e Mirroring

Os níveis compostos combinam RAID 0 (*striping*) e RAID 1 (*mirroring*) em uma hierarquia de dois níveis, e a ordem de aplicação produz diferenças significativas na tolerância a falhas [?].

No RAID 0+1 (*stripe-then-mirror*), os dados são primeiro distribuídos em *stripes* entre grupos de discos e depois cada grupo é espelhado integralmente. A falha de um disco degrada metade inteira do espelho (o *stripe* completo), reduzindo a tolerância geral. No RAID 10 (*mirror-then-stripe*), pares de discos são primeiro espelhados e depois combinados em um *stripe*. A falha de um disco afeta apenas o par local, e o sistema tolera múltiplas falhas desde que não ocorram ambas no mesmo par [?]. O

RAID 10 costuma ser preferido pela melhor resiliência a falhas múltiplas e pela reconstrução localizada — apenas o par afetado precisa ser reconstruído. Ambos utilizam 50% da capacidade bruta.

Em SBDs, o RAID 10 é a configuração recomendada para servidores OLTP de alto desempenho (Oracle, SQL Server, PostgreSQL), onde leitura e escrita são intensivas e a disponibilidade é crítica [?, ?]. O custo de espaço é justificado pela ausência de penalidade de cálculo de paridade nas escritas. Quando combinado com interfaces SAS com suporte e ativação de proteção fim-a-fim em toda a cadeia, o RAID 10 pode oferecer um perfil adequado a cargas transacionais, mas a escolha precisa ser comparada a outras mídias e configurações com a mesma carga.

7.10 Tabela Comparativa dos Níveis RAID Padrão

Nas tabelas, n é o total de discos ativos e C a capacidade de cada disco. Adota-se RAID 10 clássico com pares de espelhos; implementações como Linux MD admitem layouts diferentes, que não devem ser confundidos com essa topologia [?]. Capacidades são limites nominais, sem hot spares e metadados.

Nível	Mínimo	Capacidade	Falhas toleradas	Fonte / acesso
0	2	nC	Nenhuma	[?]; 10/09/2026
1	2	C	$m - 1$ em m cópias	[?]; 10/09/2026
2	ECC	kC	Depende do código; Hamming simples corrige uma falha	[?]; 10/09/2026
3	3	$(n - 1)C$	Uma	[?]; 10/09/2026
4	3	$(n - 1)C$	Uma	[?]; 10/09/2026
5	3	$(n - 1)C$	Uma	[?]; 10/09/2026
6	4	$(n - 2)C$	Quaisquer duas	[?]; 10/09/2026
0+1	4	$nC/2$	Uma garantida; outras apenas no grupo já perdido	[?]; 10/09/2026
10	4	$nC/2$	Uma por par; até $n/2$ se em pares distintos	[?]; 10/09/2026

Tabela 4: Capacidade e tolerância dos layouts clássicos. Em RAID 2, k conta discos de dados; os demais dependem do ECC. Mínimos convencionais, não restrições universais de software.

Nível	Leitura / escrita	Vantagem e custo	Uso e fonte / acesso
0	Paralelismo sem redundância	Capacidade integral; falha compromete volume	Temporários reconstruíveis. [?]; 10/09/2026
1	Leituras divididas; escritas replicadas	Rebuild pela cópia; custo de capacidade	WAL e volumes críticos. [?]; 10/09/2026
2/3	Transferência conjunta; baixa concorrência independente	Paralelismo por requisição; organização histórica	Estudo de ECC e distribuição fina. [?]; 10/09/2026
4	Leituras independentes; paridade concentra escritas	Simplicidade; contenção na paridade	Implementações com gestão específica de escrita. [?]; 10/09/2026
5	Boa distribuição; RMW penaliza pequenas escritas	Uma unidade de capacidade em paridade	Leitura intensa com risco aceito. [?]; 10/09/2026
6	Dados diretos; duas paridades nas atualizações	Duas falhas; maior custo de escrita/rebuild	Capacidade e proteção adicional. [?]; 10/09/2026
0+1/10	Leitura paralela; escrita duplicada	Sem cálculo de paridade; metade da capacidade	OLTP; preferir 10 pelo isolamento de falhas por par. [?]; 10/09/2026

Tabela 5: Síntese comparativa por tipo de operação, sem promessas universais de desempenho.

7.11 Exemplo comparativo de dimensionamento

Considere oito discos idênticos de 4 TB: RAID 0 fornece 32 TB; RAID 10, 16 TB; RAID 5, 28 TB; RAID 6, 24 TB. São cálculos próprios aplicando as expressões anteriores. A capacidade adicional de RAID 5 deve ser confrontada com sua menor tolerância durante o rebuild, não apenas com o custo por terabyte.

Para mostrar o efeito de pequenas escritas aleatórias, suponha 150 IOPS por disco, 70% de leituras e 30% de escritas, sem cache, com carga uniformemente distribuída. Se p é o número de I/Os físicos por escrita, uma estimativa por contagem de operações é

$$I_{\log} \approx \frac{nI_{\text{disco}}}{f_L + pf_E}.$$

Para espelhamento, $p = 2$; para RMW de RAID 5, $p = 4$; para dupla paridade com três leituras e três escritas, $p = 6$. O cenário resulta, respectivamente, em aproximadamente 923, 632 e 480 IOPS lógicos. São resultados calculados, não medições: ignoram diferenças de custo entre leitura e escrita, dependências temporais do RMW e efeitos do controlador. Escrita sequencial de stripes completas exige outro modelo. A utilidade do exemplo é mostrar por que a proporção de escritas altera a escolha.

Com quatro discos, o RAID 10 formado por pares (A, B) e (C, D) suporta perder A e C , mas não A e B . No RAID 0+1 com grupos (A, B) e (C, D) , perder A inutiliza o primeiro grupo; perder depois C compromete o espelho inteiro. Este exemplo próprio explicita que “tolerar duas falhas” em RAID 10 depende de quais discos falham.

Desempenho normal, degradado e em reconstrução. No espelho saudável, leituras podem ser divididas entre cópias; perdido um membro, o sobrevivente concentra os acessos e fornece dados ao rebuild. Em RAID 5, uma leitura de dado ausente requer reconstrução com os sobreviventes; leituras de dados presentes podem continuar diretas. Em RAID 6, o custo depende das posições perdidas e do código empregado. Em todos os níveis redundantes, reconstrução e aplicação competem por banda e IOPS, podendo elevar a latência. Não existe fator universal de perda de desempenho: importa medir a carga normal, degradada e durante o reparo, inclusive os percentis de latência [?, ?].

7.12 Integridade, reconstrução e limites da proteção

RAID protege contra determinadas falhas físicas. Exclusão acidental e corrupção lógica podem ser propagadas às cópias; a proteção exige backups independentes com restauração testada. Alta disponibilidade do SBD também depende de host, controladoras, caminhos, energia e mecanismos de recuperação.

Em RAID com paridade, queda de energia entre a gravação de dados e de paridade pode deixá-los inconsistentes: é o *write hole*. Implementações usam mecanismos como journal ou cache protegido; o simples uso de XOR não torna uma atualização atômica [?]. Durante a reconstrução, um erro de leitura irreversível em um sobrevivente pode impedir recompilar parte dos dados. Isso difere da perda completa de um segundo disco.

Checksums e scrubbing periódico ajudam a detectar problemas latentes, mas é necessário identificar a cópia correta antes de reparar. Paridade inconsistente não informa, sozinha, qual bloco está errado; reconstruir a partir de dados corrompidos pode propagar o erro [?]. Hot spare reduz a espera pelo

início da reconstrução, sem aumentar a quantidade de paridades do nível escolhido. A carga de rebuild deve ser dimensionada junto da aplicação e do tempo de recuperação aceitável.

8 Níveis de RAID Não Padrão

Essas designações identificam produtos, algoritmos ou modos de configuração. Não formam uma escala de qualidade: o número maior não implica maior confiabilidade. A implementação e a documentação do produto definem as propriedades aplicáveis.

8.1 RAID 1.5 (HighPoint)

O manual primário HPT370/372N da HighPoint, revisão 1.0 de fevereiro de 2003, identifica RAID 1.5 como modo de espelho, com duplicação e reconstrução após falha. O manual DFI com controlador HighPoint 372N descreve distribuição e espelhamento usando dois discos [?, ?]. Trata-se de tecnologia ATA histórica, vinculada ao controlador documentado.

O objetivo é combinar leitura pelos dois membros com redundância de cópia. Para dois discos iguais completamente espelhados, a capacidade útil é a de um disco e uma falha pode ser tolerada; essa conclusão decorre da duplicação, não do número “1.5”. A vantagem é obter redundância em uma instalação pequena. A desvantagem é depender de controladora, driver e recuperação específicos, sem evidência de superioridade geral sobre RAID 1. Sua aplicação neste estudo é manutenção de sistemas legados; RAID 1.5 não deve ser confundido com RAID 15 ou RAID 10. Os manuais consultados são cópias históricas hospedadas por terceiros.

8.2 RAID 7 (Storage Computer Corporation)

A documentação societária da própria Storage Computer descreve RAID 7 como tecnologia proprietária empregada nas linhas StorageSuite e OmniRaid. A arquitetura reúne controladores, memória centralizada e distribuída, mapeamento proprietário e sistema operacional de tempo real [?]. O objetivo é desacoplar o atendimento ao host das operações internas e explorar cache e concorrência no subsistema.

A vantagem potencial é reduzir latência percebida e coordenar múltiplos acessos; o desempenho sustentável continua limitado pelo destage e pelos discos. As desvantagens são dependência da implementação, recuperação do cache e suporte do fabricante. Não há uma fórmula universal de capacidade ou número de falhas dedutível do nome. Para SBDs, é uma referência histórica de arrays inteligentes: uma avaliação concreta precisa da configuração de proteção e de testes, em vez de tomar alegações comerciais como benchmark independente.

8.3 RAID-DP (NetApp)

RAID-DP utiliza duas unidades de paridade por grupo e permite recuperar quaisquer duas falhas de disco [?]. O fundamento de paridade por linhas e diagonais é documentado no trabalho de Corbett e colaboradores: RDP mantém dados sem codificação e calcula conjuntos distintos de XOR. A segunda relação permite recuperar duas perdas sem simplesmente duplicar a primeira paridade [?].

A vantagem é proteção dupla com capacidade equivalente a dois discos destinada à redundância. O custo envolve espaço, atualização das duas paridades e reconstrução. Não se deve equiparar o

desempenho do conjunto ONTAP a um RAID 6 genérico: a política de escrita e o restante do software também importam. Para bancos de dados instalados nesse ambiente, RAID-DP é uma opção de proteção local, complementada por backup e disponibilidade de controladoras. O tamanho do grupo deve seguir a documentação da versão e do hardware, sem um limite acadêmico universal.

8.4 RAID-S (EMC/Symmetrix)

O artigo técnico de Brett Quinn, da EMC, preservado pela NASA, descreve RAID-S por grupos de volumes de dados e paridade. Na configuração histórica 3+1, a capacidade útil é 75%; na variante EOS 7+1, 87,5%. Esses percentuais referem-se ao arranjo documentado, antes de outras reservas [?].

Cada volume de dados mantém seu mapeamento em um disco, sem o striping tradicional entre todos os membros; com Hyper-Volume Extension, volumes de paridade podem ser distribuídos pelos discos. Discos capazes de XOR participam do cálculo, reduzindo trabalho da controladora. A vantagem é combinar economia de capacidade e integração com cache; permanecem penalidade de atualização e dependência de hardware e microcódigo. Paridade simples não garante recuperar duas perdas no mesmo grupo, embora volumes sobreviventes possam permanecer acessíveis. A aplicação é o ambiente Symmetrix histórico, com análise específica de carga e recuperação, sem presumir adaptação automática ao padrão de acesso [?].

8.5 Intel Matrix RAID

Matrix RAID permite até dois volumes RAID sobre o mesmo conjunto físico, com combinações dependentes da controladora [?]. Por exemplo, uma região de dois discos pode ser espelhada para dados persistentes e outra usada em RAID 0 para temporários. Cada volume herda a proteção do seu nível; não se cria um nível adicional de redundância.

A vantagem é distribuir capacidade entre objetivos distintos sem adquirir outro conjunto de discos. A desvantagem é compartilhar recursos e falhas físicas: perder um membro afeta o volume RAID 0 e degrada o espelho. Para desenvolvimento ou instalações pequenas, essa flexibilidade pode ser útil; para isolamento operacional de cargas críticas, volumes no mesmo conjunto não equivalem a discos independentes.

8.6 Síntese das variantes

RAID 1.5 enfatiza espelhamento com otimização de acesso em produto legado; RAID 7, arquitetura de controladora e cache; RAID-DP, dupla paridade; RAID-S, integração de volumes e XOR no Symmetrix; Matrix, particionamento do conjunto em volumes com níveis distintos. As fontes primárias permitem distinguir inovação algorítmica de política de cache e organização comercial. A falta de padronização não demonstra ausência de mérito técnico, mas exige documentação específica para comparar e recuperar os dados.

9 Integração DAS e RAID em SBDs

A banda agregada dos discos deve ser suportada pelo controlador e seus enlaces; manutenção e caminhos redundantes também afetam a recuperação. A tabela apresenta candidatos de projeto, não regras

Variante	Fabricante	Redundância	Falhas tol.	Vantagem	Limitação / aplicação
RAID 1.5	HighPoint (ATA)	Espelhamento total	1	Redundância em 2 discos com leitura pelos dois	Dependência de controladora legada; sem ganho universal sobre RAID 1 [?].
RAID 7	Storage Computer Corp.	Proteção específica do produto	Conforme configuração	Cache centralizado; RTOS reduz latência percebida	Implementação proprietária; desempenho limitado pelo destage e pelos discos [?].
RAID-DP	NetApp (ONTAP)	Duas paridades (RDP)	2	Proteção dupla; sem duplicar capacidade inteira	Tamanho de grupo específico do ONTAP; custo de duas escritas de paridade [?, ?].
RAID-S	EMC (Symmetrix)	Paridade por volume	1 (config. 3+1)	Economia de capacidade (75% ou 87,5%); XOR no disco	Dependência de hardware e microcódigo Symmetrix; uma paridade não recupera duas perdas no grupo [?].
Matrix	Intel RST	Volumes RAID 0 e RAID 1, por exemplo	Por volume	Dois volumes em mesmo conjunto físico	Falha física afeta ambos os volumes; sem isolamento real de cargas críticas [?].

Tabela 6: Comparação das variantes proprietárias/não padrão. Capacidades e tolerâncias referem-se às configurações documentadas; generalização para outros produtos ou versões exige verificação.

universais. SATA e SAS requerem controladores compatíveis; NVMe local utiliza normalmente PCIe e exige suporte próprio, mesmo em uma placa que também ofereça SATA/SAS [?].

Carga SBD	Interfaces candidatas	RAID candidato	Justificativa
WAL / logs	SATA, SAS ou NVMe/PCIe	1 ou 10	Escrita sequencial e latência de flush/commit; avaliar cache protegido e durabilidade [?, ?].
Dados OLTP	SATA, SAS ou NVMe/PCIe	10	Candidato para atualizações aleatórias intensas; duas cópias e ausência de paridade, ao custo de capacidade [?].
Leitura intensa / OLAP	SATA, SAS ou NVMe/PCIe	5 ou 6	Capacidade versus risco; dupla paridade tolera uma falha adicional. Decidir pelo rebuild, carga e criticidade, sem limiar universal [?].
Backup externo	eSATA / USB 3.2 / USB4	1 ou sem RAID	A cópia precisa ser independente da origem; RAID local não substitui restauração testada.
Temporários	SATA, SAS, NVMe/PCIe ou USB	0	Somente conteúdo reconstruível cuja indisponibilidade seja aceitável.
Legado	FireWire	Conforme equipamento	Compatibilidade e suporte existentes; não é recomendação geral para novos SBDs [?].

Tabela 7: Candidatos de interface e RAID por carga. Mídia, persistência, capacidade, concorrência e desempenho degradado precisam ser avaliados no equipamento concreto.

Um HBA pode limitar a vazão se o enlace PCIe de conexão ao host não comportar o tráfego agregado dos discos SATA/SAS. Em NVMe, devem ser dimensionados os enlaces PCIe e eventuais switches/controladoras; não se aplica automaticamente a taxa de um enlace SAS. Hot spares podem reduzir a espera pelo início do rebuild, mas não garantem reconstrução imediata nem eliminam a competição por I/O. Nenhum nível RAID substitui backup independente testado [?].

10 Conclusão

O projeto de DAS para um SBD começa pela carga: latência de commit, proporção e tamanho das leituras e escritas, capacidade e tempo aceitável de recuperação. A interface deve atender ao fluxo agregado e aos requisitos de manutenção; a escolha entre SATA, SAS e conexão externa exige examinar o dispositivo, o controlador e os caminhos completos — e como esses parâmetros interagem com o nível de RAID conforme discutido na Seção 9.

RAID 10 é um candidato para escrita aleatória intensa, ao custo de metade da capacidade na configuração com duas cópias. RAID 5 e RAID 6 aproveitam melhor a capacidade, mas exigem avaliar atualização de paridade e operação degradada; RAID 6 suporta uma falha adicional. RAID 0 é restrito, nesta recomendação, a conteúdo recuperável por outra origem. A decisão final deve usar medições representativas e exercícios de restauração. Os modelos de MTDDL explicam tendências, enquanto backup, integridade e disponibilidade do serviço tratam riscos que o nível RAID isolado não cobre.

11 Autoria e uso de IA

Múltiplas ferramentas de IA apoiaram diferentes fases deste trabalho: organização de rascunhos, pesquisa de fontes, redação, expansão técnica, geração de artefatos $\text{\LaTeX}$ e revisão crítica dos critérios do enunciado. As ferramentas declaradas nos registros do grupo incluem GPT-5.6 Terra, Gemini 3.1, Claude Sonnet e Antigravity; nem todos os prompts têm responsável individual confirmado.

A IA **não foi tratada como fonte bibliográfica**: afirmações sobre taxas de interface, fórmulas de confiabilidade, implementações proprietárias e nomenclaturas foram confrontadas com especificações primárias (SATA-IO, T10/SAS-4, IEEE 1394, USB-IF, NIST, Silberschatz, Elmasri e Garcia-Molina). Erros identificados nessa verificação estão registrados na Tabela 9.

Os prompts-chave foram preservados nos registros da sessão e estão disponíveis no repositório.

12 Post-Mortem

12.1 Divisão de responsabilidades

A tabela a seguir reproduz a divisão de autoria registrada pelo grupo.

Integrante	Responsabilidades e decisões
Daniel R. S. Barros	Interfaces DAS: SATA, eSATA, SAS, FireWire, USB e HBA. Priorizou documentação técnica primária para dados de interface.
Hugo Leandro Antunes	RAID 0–4, <i>striping</i> e blocos de paridade. Organizou a explicação por granularidade de distribuição, relacionando arquitetura, paralelismo e gargalos de escrita.
Jeson Wen Chen	RAID 5/6 e métricas MTTF, MTTR, MTBF e MTDDL. Explicitou hipóteses das fórmulas e evitou limiar universal para RAID 6.
João Batista B. Junior	RAID 0+1/10, RAID não padrão e comparação de aplicações em SBD. Diferenciou níveis compostos e qualificou implementações proprietárias.
Pedro Cintra Silveira	Integração do $\text{\LaTeX}$, slides, referências e revisão final de coerência. Manteve consistência entre relatório, slides e checklist de entrega.

Tabela 8: Divisão de responsabilidades entre os integrantes.

12.2 Decisões do grupo

O grupo adotou a proposta como fonte de verdade para escopo e entrega. Para interfaces atuais e RAID proprietário, decidiu usar documentação oficial ou explicitar a limitação da fonte. Decidiu também não aplicar limiar universal de número de discos para recomendar RAID 6 — a escolha depende de MTTR, capacidade, carga, criticidade e risco operacional, conforme discutido nas equações de MTDDL.

12.3 O que a revisão corrigiu

A revisão técnica executada pelas ferramentas de IA corrigiu riscos recorrentes: separou AHCI (interface de programação) de SATA (protocolo físico) e de NVMe (protocolo distinto sobre PCIe); tratou *byte-level striping* como granularidade própria distinta de *bit-level*; explicitou as hipóteses do modelo de Markov para MTDDL e a convenção de contagem de MTBF; removeu afirmação de tolerância universal para RAID 7; eliminou limiares sem base normativa para RAID 6; separou RAID 0+1 de RAID 10 com exemplo de quais falhas cada topologia tolera; e registrou a distinção entre *mirroring/shadowing* de hardware e *shadow paging* transacional. Foram também removidas comparações quantitativas sem benchmark contextualizado.

12.4 Erros gerados pela IA e correções realizadas

#	Onde	Erro gerado pela IA	Correção e fonte	Quem corrigiu
1	RAID 2 e Tabela comparativa	Foi informado “mínimo: 3 discos” como regra universal.	O número de discos de redundância depende da implementação do código de Hamming e da quantidade de discos de dados; removida a regra universal. Base: Elmasri e Navathe, Seção 16.10.	Hugo
2	RAID-DP	Foram atribuídos algoritmo interno e limite universal de 28 discos sem fonte primária suficiente.	Mantidas duas paridades e duas falhas; fundamento RDP acrescentado com fonte primária [?]; tamanho de grupo continua específico do ONTAP.	João
3	RAID-S	Foi descrito como algoritmo que adapta dinamicamente a distribuição de dados conforme o acesso.	Corrigido: RAID-S é tecnologia proprietária Symmetrix baseada em grupos de volumes de dados e paridade; não há evidência de adaptação dinâmica. Base: documentação técnica histórica NASA/EMC.	Pedro
4	Interfaces DAS	A tabela usava “SATA II/III” e atribuída “MTBF relativo” à interface, como atributo do protocolo.	Adotada a nomenclatura SATA-IO; confiabilidade passou a ser atributo do disco, firmware, ambiente e controlador. Base: SATA-IO.	Daniel
5	Interfaces	SAS-4: agregado de 4.500 MB/s; filas SAS fixadas em 256.	Corrigido cálculo para 4.800 MB/s e fila dependente do produto [?, ?].	Daniel
6	SATA/USB	AHCI confundido com protocolo físico; energia USB vinculada à geração.	Separadas interface de programação, transporte e Power Delivery [?, ?].	Daniel
7	eSATA	Origem atribuída à revisão SATA 2.6.	Especificações externas datadas de 2004 [?].	Daniel
8	RAID 1.5/7	Atribuição a LSI/Broadcom e descrições sem detalhamento de funcionamento.	Identificada HighPoint; aprofundado RAID 7 com documentação primária [?, ?].	João
9	Confiabilidade	Igualdades de MTDL sem modelo de reparo suficiente; MTBF sem convenção.	Derivadas aproximações com reparo serial exponencial e delimitada contagem de tempo [?].	Jeson
10	RAID 5/WAL	Quatro I/Os em toda escrita; commit sempre aguardando ambos os discos.	Separados RMW/full stripe, cache e modos de durabilidade [?, ?].	Jeson
11	Integridade	Redundância apresentada como garantia de serviço ininterrupto.	Acrescentados limites, write hole, checksums e recuperação [?, ?].	Jeson

Continua na próxima página...

Tabela 9 – Continuação da página anterior

#	Onde	Erro gerado pela IA	Correção e fonte	Quem corrigiu
12	Bibliografia	Link IBM genérico e PostgreSQL 16 com URL current.	Substituídas fontes e fixada versão; corrigida autoria do artigo EMC preservado pela NASA.	Pedro
13	Shadowing	Confusão entre espelhamento físico e ponto de commit na paginação sombra.	Separadas camadas e descrita troca atômica da referência persistente [?, ?].	Hugo
14	Comparação	Eficiência fixa de RAID 1 com múltiplas cópias e avaliações vagas de escrita.	Usada eficiência 1/m; comparadas cargas e acrescentados exemplos calculados.	Pedro

Tabela 9: Erros gerados pela IA, correções aplicadas e responsáveis.

Referências bibliográficas