

Arquiteturas de Armazenamento Físico para SBD

DAS, Interfaces e Níveis de RAID

Daniel Rebouças de Sousa Barros — DRE 123273542

Hugo Leandro Antunes — DRE 123143543

Jeson Wen Chen — DRE 123051893

João Batista Brasil Junior — DRE 121091172

Pedro Cintra Silveira — DRE 123419342

Universidade Federal do Rio de Janeiro — Construção de Bancos de Dados

Prof. Milton Ramirez — Setembro de 2026

O caminho de uma escrita durável



O commit só é seguro quando a confirmação chega ao ponto de durabilidade exigido pelo SGBD — não basta o dado estar no cache volátil do HBA.

OLTP

Latência de cauda nas escritas síncronas
(WAL flush)

OLAP / Scans

Vazão sustentada em leituras
sequenciais


Rebuilds

Competição entre reconstrução e carga
da aplicação

DAS e suas interfaces

Interface	Taxa de enlace	Conexão / manutenção	Protocolo / aplicação
SATA interno	Até 6 Gb/s; 600 MB/s após 8b/10b	Cabo até 1 m; hot-plug condicionado	Comandos ATA; AHCI (programação). Capacidade econômica.
eSATA	Taxa da geração SATA suportada	Até 2 m; alimentação separada	Transporte SATA externo; expansão e backup.
SAS-4	22,5 Gb/s por direção; 2.400 MB/s	Comprimento e filas dependem do produto; caminhos redundantes quando suportados	SCSI full-duplex; gerenciamento de storage missão crítica.
FireWire	Classes 400/800 Mb/s (50/100 MB/s)	Alcance depende do modo e meio	IEEE 1394; isócrono e assíncrono; instalações legadas.
USB 3.2	5/10/20 Gb/s	Cabo compatível com o modo; hubs compartilham banda	SuperSpeed; BOT ou UASP para armazenamento.
USB4 v2.0	Até 80 Gb/s; opcional 120/40 Gb/s assimétrico	Cabos passivos 40 Gb/s ou ativos 80 Gb/s	PCIe/USB/DP tunelados; banda compartilhada.
HBA	Depende de PCIe e enlaces de storage	Hot-plug de discos e placa são recursos distintos	Passthrough ou RAID offload conforme o produto.

SATA, SAS e o papel do HBA



HBA passthrough


- Expõe discos ao SO
- RAID por software (mdadm, ZFS)
- CPU do host processa paridade

Controladora RAID

- Volumes lógicos ao SO
- Cache protegido no adaptador
- Confirmar: BBU ou flash-backed

Cache volátil sem proteção não substitui persistência. Confirmar a política antes de confiar no ack de escrita.

Fundamentos de RAID: paralelismo e redundância



Bit-level striping

Bit i no disco i .

Paralelo por byte; bloqueia todos os braços por requisição. Base do RAID 2.

Byte-level striping

Byte j no disco $(j \bmod n)$.

Alta taxa sequencial; sem concorrência de requisições. Base do RAID 3.

Block-level striping

Bloco lógico i no disco $(i \bmod n) + 1$.

Equilíbrio: paralelismo em scans + concorrência em OLTP. Base do RAID 0, 4, 5 e 6.

Mirroring, shadowing e paridade XOR

Mirroring / shadowing (hardware)

- Cópias físicas idênticas em discos distintos — base do RAID 1
- Silberschatz e Elmasri usam os dois termos como sinônimos no contexto de hardware
- Leituras distribuídas entre cópias; escrita limitada pelo disco mais lento
- Reconstrução pela cópia sobrevivente — sem cálculo de paridade

Paridade XOR

$$P = B_1 \oplus B_2 \oplus \dots \oplus B_{n-1}$$

$$B_i = P \oplus B_1 \oplus \dots \oplus B_{i-1} \oplus B_{i+1} \oplus \dots$$

Exemplo: $D_0 = 1010, D_1 = 1100, D_2 = 0110 \rightarrow P = 0000$.

Perdido D_1 : $D_1 = P \oplus D_0 \oplus D_2 = 1100 \checkmark$

Shadow paging é técnica *transacional* distinta: mantém estado anterior das páginas para garantir atomicidade no SGBD — não é redundância de disco.

Métricas de confiabilidade

Métrica	O que mede	Fórmula-chave
MTTF	Tempo médio até falha de um componente	$MTTF_{\text{grupo}} = M/n$
MTTR	Tempo médio de reparo + reconstrução	janela de vulnerabilidade
MTBF	Intervalo médio entre falhas (sistema reparável)	$MTBF_{\text{op}} = U; \quad T_{\text{ciclo}} = U + D$
MTTDL	Tempo médio até perda permanente de dados	depende do nível


$$MTTDL_{\text{RAID } 5} \approx \frac{M^2}{n(n-1)R} \quad MTTDL_{\text{RAID } 6} \approx \frac{M^3}{n(n-1)(n-2)R^2}$$

Reduzir $\$R\$$ (MTTR) à metade duplica o MTTDL de RAID 5 e quadruplica o de RAID 6. Hot spares reduzem $\$R\$$ sem aumentar paridades.

Níveis de RAID padrão

Nível	Mín.	Capacidade	Falhas tol.	Escrita	Aplicação em SBD
0	2	nC	0	Sem overhead	Temporários reconstruíveis
1	2	C	$m - 1$ em m cópias	Replicada	WAL, logs e metadados
2	ECC	kC	1 (Hamming)	Coordenada	Histórico — ECC agora interno ao disco
3	3	$(n - 1)C$	1	Todos os discos	Histórico — byte-level, sequencial
4	3	$(n - 1)C$	1	RMW 4 I/Os + gargalo paridade	Raramente usado; RAID 5 substitui
5	3	$(n - 1)C$	1	RMW 4 I/Os — paridade distribuída	OLAP, leitura intensa
6	4	$(n - 2)C$	2	RMW 6 I/Os — dupla paridade	Arrays grandes, discos ≥ 4 TB
0+1	4	$nC/2$	1 garantida	Replicada	Preterido frente ao RAID 10
10	4	$nC/2$	1 por par	Replicada	OLTP pesado, missão crítica

RAID 4 vs. RAID 5: o gargalo de paridade



RAID 4 → 4 I/Os físicos por small write


Disco de paridade participa de **toda** escrita → ponto único de contenção

RAID 5 → mesmos 4 I/Os, mas paridade distribuída

Na stripe k , paridade no disco $(k \bmod n)$ → contenção balanceada entre todos

Escrita de stripe completa elimina as 2 leituras (calcula paridade direto dos dados novos), mas o disco de paridade ainda participa.

RAID 0+1 vs. RAID 10: tolerância real



RAID 0+1

Perder disco A → stripe inteira degradada.

Perder C depois → espelho **inteiro** comprometido.

RAID 10

Perder A → apenas par (A,B) degradado.

Perder C → apenas par (C,D) degradado.

Tolera A+C simultaneamente.


RAID 10 tolera até $n/2$ falhas *desde que não sejam no mesmo par*. Reconstrução localizada: só o par afetado é reconstruído.

RAID não padrão: variantes proprietárias

Variante	Fabricante	Redundância	Falhas tol.	Destaque	Limitação
RAID 1.5	HighPoint (ATA legado)	Espelhamento total	1	Redundância em 2 discos com leitura pelos dois	Dependência de controladora legada
RAID 7	Storage Computer Corp.	Específica do produto	Conforme config.	Cache centralizado; RTOS reduz latência percebida	Proprietário; limitado pelo destage e pelos discos
RAID-DP	NetApp / ONTAP	Duas paridades (RDP)	2	Proteção dupla sem duplicar capacidade	Tamanho de grupo específico do ONTAP
RAID-S	EMC / Symmetrix	Paridade por volume	1 (config. 3+1)	75–87,5 % de eficiência; XOR no disco	Hardware e microcódigo Symmetrix
Matrix	Intel RST	Volumes mistos (ex.: 0+1)	Por volume	Dois volumes no mesmo conjunto físico	Falha física afeta ambos os volumes

Número maior ≠ maior confiabilidade. Cada variante exige documentação específica do produto para avaliar proteção, capacidade e recuperação.

Desempenho normal, degradado e em rebuild



Normal

RAID 5/6: lê dados diretamente.
RAID 1/10: distribui leituras entre cópias.

Degradado

RAID 5: toda leitura do dado ausente exige reconstrução via XOR com os sobreviventes.
RAID 6: depende de quantos e quais discos falharam.

Rebuild

Compete por banda e IOPS com a aplicação.
Não existe fator universal de perda de desempenho — medir latência de cauda e percentis.

RAID não substitui backup. Corrupção lógica e deleção acidental propagam-se às cópias. Uma cópia só está pronta depois de um restore testado.

Integração DAS + RAID no SBD

Carga SBD	Interfaces candidatas	RAID candidato	Justificativa
WAL / logs	SATA, SAS ou NVMe/PCIe	1 ou 10	Escrita sequencial; avaliar cache protegido e durabilidade
Dados OLTP	SAS ou NVMe/PCIe	10	Escritas aleatórias intensas; sem penalidade de paridade
OLAP / DW	SATA ou SAS	5 ou 6	Capacidade vs. proteção; RAID 6 para discos grandes
Backup externo	eSATA / USB 3.2 / USB4	1 ou sem RAID	Redundância local; backup independente é obrigatório
Temporários	Qualquer	0	Somente conteúdo reconstruível / descartável
Legado	FireWire	Conforme equipamento	Compatibilidade existente; não é recomendação para novos SBDs

Banda da interface deve superar a I/O agregada dos discos. Hot spare encurta o MTTR e impacta diretamente o MTDDL de RAID 5 e 6.

Casos e verificações práticas

PostgreSQL em RAID 1 (WAL)

Espelhamento sem penalidade de paridade; durabilidade depende do cache e do fsync.

OLTP em RAID 10 + SAS

Full-duplex + caminhos redundantes; reconstrução localizada ao par afetado.

OLAP em RAID 5 + SATA

Custo/TB favorável; avaliar MTTR em discos grandes — RAID 6 se risco for alto.

RAID-DP (NetApp ONTAP)

Dupla paridade (RDP); tamanho de grupo e política de rebuild específicos do sistema.

Antes de produção, testar

- Perder um disco, um caminho e uma controladora
- Reiniciar durante escrita e durante rebuild
- Medir latência normal e degradada
- Restaurar backup integral e pontual

Revisões desta pesquisa

- Distinção AHCI/SATA/NVMe como protocolos separados
- Byte-level striping separado de bit-level
- MTDDL com hipóteses do modelo explicitadas
- RAID 7 sem tolerância universal afirmada
- Limiares de RAID 6 removidos — decisão por carga e risco

Conclusão

A decisão começa pela carga exigida pelo database engine

- **Interface:** banda, latência, manutenção e caminhos redundantes antes de escolher o nível RAID.
- **RAID 10** é candidato natural para OLTP intenso — sem cálculo de paridade, reconstrução localizada.
- **RAID 5 / 6** aproveitam melhor a capacidade; RAID 6 suporta uma falha adicional ao custo de escrita.
- **RAID 0** restrito a dados descartáveis — MTDL menor que um disco isolado.
- **Nenhum nível RAID substitui backup independente testado.**